

共情 AI 的簡化模型

一、問題設計

這個想法的最終願景是希望能夠構建一個具備「共情」能力的 AI 助理，不僅能辨識表層情緒，還能結合用戶的長期記憶來推斷深層的「情感意圖」，像是能夠區分用戶感到傷心是因為「被忽略的失落」還是「努力後失敗的無力」。為了達成這個複雜的目標，我們將問題簡化為 **PCER (Personalized Contextual Emotional Retrieval)** 任務。

這個簡化問題將「共情」解構為兩個可量化的核心能力：**多模態感知與情境關聯**。若模型能在此階段準確地將「當下的情緒訊號」與「過去的記憶片段」連結起來，便證明了 AI 具備了理解情感語境的基礎，為未來引入 RLHF 進行策略性回應生成奠定邏輯基礎。

這個是一個**多模態分類與檢索**的聯合任務：

- 輸入 (Input)：**模型接收三種數據流，(1) T_q (**文字輸入**)，即用戶當下的短語句；(2) A_q (**聲學輸入**)，包含語氣與語調特徵；(3) M_h (**長期記憶**)，這是一組包含用戶過去生活事件與對話紀錄的情境段落集合。
- 輸出 (Output)：**模型需產生兩個結果，(1) L_i (**情感意圖標籤**)，這是對用戶心理動機的分類預測；(2) C_r (**情境檢索結果**)，即從記憶庫中選出與當前情緒最相關的單一過去事件。
- 任務目標：**在單次推論中，準確預測 L_i 並檢索出正確的 C_r 。
- 資料形式：**資料集由成對的 (T_q, A_q) 樣本組成，每個樣本附帶一組人工合成的個人歷史庫 M_h ，並標註了正確的意圖類別與關鍵過去事件索引。

二、模型與方法

模型選擇：多模態 Transformer (Multimodal Transformer)

具體架構可參考輕量化的 Vision-Language Model, VLM 作為核心模型。

選擇理由：

- 特徵融合能力：**人類的情感意圖往往隱藏在文字與聲音的交互作用中，像是一句正面的話配上相對低沉的語調可能會帶有諷刺意圖。Transformer 架構中的自注意力機制(Self-Attention)是目前融合跨模態特徵最有效的方法，能

將 T_q 與 A_q 整合為一個的情境向量。

2. **邊緣運算的壓縮潛力：**針對長期記憶 M_h 的處理，傳統純文字輸入會導致 Token 數量過多，造成邊緣設備的運算不堪負荷。根據最新的研究，將長文本儲存為圖像輸入到多模態模型中，能顯著減少解碼器所需的 Token 數量，通常可節省近乎一半的計算量，這對於在資源受限的邊緣設備上處理長篇幅的個人歷史記憶有重大幫助。

參考資料：**Text or Pixels? It Takes Half: On the Token Efficiency of Visual Text Inputs in Multimodal LLMs**(Yanhong Li, Zixuan Lan, Jiawei Zhou, 2025, cs.CL)

實作方法：

我們採用**監督式學習**搭配**對比損失**的策略：

1. **記憶視覺化編碼：**為了優化邊緣效率，我們先將 M_h 中的長文本段落轉換為圖像，再利用 VLM 的視覺編碼器將其轉換為緊湊的視覺 Tokens，這能夠讓模型能以更低的運算成本閱讀大量歷史資訊。
2. **雙頭輸出機制：**模型在融合了用戶輸入與壓縮後的記憶特徵後，分流至兩個輸出頭，(1) **分類頭**，使用交叉熵損失函數(Cross-Entropy Loss)來訓練 L_i 的預測準確度；(2) **檢索頭**，計算情境向量與記憶庫中各段落的相似度，利用對比損失函數來最大化正確情境 C_r 的分數。

結合這兩種方法，不僅可以驗證 AI 的共情能力，同時也實踐了適合未來邊緣化部署的高效記憶檢索機制。