

Week 1-10 Unanswered Questions

111652042 顏友君

1. 在 **gradient descent algorithm** 中，如果一直使用固定的 **learning rate** 可能會導致：

- (1) 如果 **learning rate** 設定太小，收斂的速度就會很慢，
- (2) 如果 **learning rate** 設定太大，當接近最低點時就有可能會跑過頭，導致 θ 在最低點旁震盪，就到不了最佳解。

為了避免這些情況，可以剛開始先設定一個較大的 **learning rate**，再設定一格像是 0.99 的參數，每跑完一次就讓 **learning rate** * 0.99，就可以同時避免 **learning rate** 太大或太小的問題。

(P.S. 這題我當初有自己回答，故沒有附上參考文獻)

2. 我們課堂中所舉例的神經網路模型都是比較小的數字，像是 4 層、5 層而已，那如果太多層會發生什麼事？有辦法找到「最佳層數」嗎？

- a. 層數太多主要會遇到三個問題：

- (1) 梯度消失與梯度爆炸 (Vanishing and Exploding Gradients)
- (2) 退化問題 (Degradation Problem)

可利用殘差網路 (Residual Networks, ResNet) 來解決。

文獻支持: **Deep Residual Learning for Image Recognition** (Kaiming He, Xiangyu Zhang, Shaoqing Ren, Jian Sun, 2016, CVPR)

(<https://arxiv.org/abs/1512.03385>)

- (3) 計算資源和數據需求

- b. 沒有一個通用的公式或理論可以直接計算出「最佳」層數。深度學習中的層數選擇是一個高度依賴任務類型、數據集大小、計算資源和模型架構的經驗性問題。

但可以通過系統化搜索與優化來尋找一個較優的層數，例如神經網路架構搜索 (Neural Architecture Search, NAS)。

文獻支持: **Learning Transferable Architectures for Scalable Image Recognition** (Barret Zoph, Quoc V. Le, 2018, CVPR)(<https://arxiv.org/abs/1707.07012>)

3. 經過觀察，我發現在 MLE 中的 Log-likelihood function 看起來很像我們 Week1 所學過的 Loss function，只差了一個負號，它們之間有什麼特別的關係嗎？

它們在數學上是等價的，只是優化目標相反。MLE 的目標是最大化 Log-Likelihood，而機器學習的目標是最小化 Loss Function，這兩種優化目標可以通過取負號來轉換。

參考文獻: *Deep Learning*(Ian Goodfellow, Yoshua Bengio, Aaron Courville, 2016, MIT Press)(Chapter 5: Machine Learning Basics, Section 5.5: Maximum Likelihood Estimation)(<https://www.deeplearningbook.org>)

4. 在 Programming assignment 的實作中，我發現當遇到非線性的資料集時，用 logistic regression 可能不是個好選擇，所以發現還可以利用 random forest，但我對 random forest 也沒有了解的很透徹，想知道它也有什麼限制條件嗎？或是哪些條件下較適合使用它？

限制條件

- (1) 無法外推 (Extrapolation)：這是最大缺點，它無法預測「訓練資料範圍之外」的數值(例如：沒看過大於 100 的輸入，就預測不出大於 100 的結果)。
- (2) 對多類別特徵有偏差：若某個特徵的類別數非常多，模型會傾向認為它很重要(偽陽性)。
- (3) 黑盒子：不像線性回歸能直觀解釋係數意義，只能給出特徵重要性排序。

適合使用的情況

- (1) 資料非線性：當資料特徵間有複雜的非線性關係，線性模型無法處理時。
- (2) 懶得做前處理：不需要對資料進行標準化或常態化。
- (3) 高維度或雜訊多：內建特徵選擇，且對異常值容忍度高，不易過擬合。

參考文獻: *Random Forests. Machine Learning* (Breiman, L., 2001, 45(1), 5–32)(<https://doi.org/10.1023/A:1010933404324>),

Bias in random forest variable importance measures (Strobl, C., et al., 2007, *BMC Bioinformatics*, 8(25))(<https://doi.org/10.1186/1471-2105-8-25>)

5. 在課堂中提到的 LDA 主要是用來做分類(classification)，如果 LDA 用來做降維(dimension reduction)的話，還需要有標籤(labels)嗎？若需要的話，是否也需要假設資料為 Gaussian distribution？

- a. 是的，絕對需要。LDA 是一種監督式學習的降維技術。它的核心目的是找到一個投影軸，使得不同類別之間的距離最大化，同時讓同一類別內的數據越緊密越好。為了計算這些距離，必須事先知道每筆資料的類別標籤。

文獻支持: **The use of multiple measurements in taxonomic problems** (R. A.

Fisher, 1936, *Annals of Eugenics*)

(<https://lgross.utk.edu/Math589Fall2020/RAFisher1936measurementsFlowerTaxa.pdf>)

- b. 理論上是需要的。雖然在數學操作上 (Fisher 的準則)，即使資料不是高斯分佈也能算出降維的投影軸，但如果要確保這個投影軸能保留最多的類別區分資訊，則依然依賴資料服從多變量常態分佈且共變異數矩陣相同的假設。如果資料分佈非常複雜 (例如彎曲的流形分佈)，LDA 降維後的結果通常會導致不同類別重疊在一起。

文獻支持: **Pattern Recognition and Machine Learning** (Christopher M. Bishop,

2006, Springer)([https://github.com/Benlau93/Data-Science-](https://github.com/Benlau93/Data-Science-Curriculum/blob/8fd5262f571c21867ed50bc3b2e0c1504970136e/Bishop-Pattern-Recognition-and-Machine-Learning-2006.pdf)

[Curriculum/blob/8fd5262f571c21867ed50bc3b2e0c1504970136e/Bishop-Pattern-Recognition-and-Machine-Learning-2006.pdf](https://github.com/Benlau93/Data-Science-Curriculum/blob/8fd5262f571c21867ed50bc3b2e0c1504970136e/Bishop-Pattern-Recognition-and-Machine-Learning-2006.pdf))

6. 在 Programming assignment 的實作中，我們知道分類模型的目標是劃分非線性的海岸線，而回歸模型的目標是預測平滑的溫度場。因此，我們對這兩個不同模型使用了不同的特徵轉換，像是在分類模型的經緯度特徵中加入了二次多項式特徵，而回歸模型則只使用原有的經緯度特徵，這種不同的特徵選擇策略對組合模型 $h(x)$ 的整體性能會造成多少影響？

根據 Cragg (1971) 提出的兩階段模型理論，分類階段(是否為陸地)與回歸階段(溫度的數值)可視為兩個獨立的隨機過程。Guyon & Elisseeff (2003) 亦指出特徵的有效性取決於特定模型的目標。

因此，我們採取差異化的特徵策略：在分類階段引入多項式特徵以捕捉非線性的海岸線邊界，而在回歸階段保持特徵簡潔以符合溫度場的平滑特性。這種策略有效提升了組合模型 $h(x)$ 在邊界處的判別能力，同時避免了回歸預測的過擬合。

文獻支持：**Some Statistical Models for Limited Dependent Variables with Application to the Demand for Durable Goods** (John G. Cragg, 1971, *Econometrica*)(<http://dx.doi.org/10.2307/1909582>), **An Introduction to Variable and Feature Selection** (Isabelle Guyon, André Elisseeff, 2003, *Journal of Machine Learning Research*) (<https://www.jmlr.org/papers/volume3/guyon03a/guyon03a.pdf>)

7. Vincent 的這篇論文都是在討論單一雜訊水平 σ ，但現代的 diffusion Models 使用的是包含多個雜訊水平的雜訊排程(noise schedule)，這個單一 σ 到多個 σ 的過程是怎麼演變的，或是有哪些功能進化了？

(1) 單一 σ 的局限

Vincent (2011) 證明了 DAE 等同於在單一雜訊 σ 下做分數匹配。這導致了兩難：

σ 太小，會讓模型在遠離資料的區域(低密度區)無法準確估計方向，導致生成失敗； σ 太大，模型看到的都是模糊的資料，生成的結果會缺乏細節。

文獻支持: **A Connection Between Score Matching and Denoising Autoencoders** (Pascal Vincent, 2011, *Neural Computation*)(https://www.iro.umontreal.ca/~vincentp/Publications/smdae_techreport.pdf)

(2) 多重 σ 的演變

現代擴散模型(如 NCSN, DDPM)不再只選一個 σ ，而是設計了一個從大到小的雜訊排程 (Noise Schedule) $\{\sigma_1, \sigma_2, \dots, \sigma_L\}$ 。

模型不再只學一個狀態，而是變成條件模型 $s_\theta(x, \sigma)$ ，學會在不同雜訊強度下該怎麼做。

文獻支持: **Generative Modeling by Estimating Gradients of the Data Distribution** (Yang Song, Stefano Ermon, 2019, *NeurIPS*) (<https://arxiv.org/abs/1907.05600>)

(3) 功能進化

- a. 解決「導航」問題 (Mixing)：大雜訊能覆蓋整個數據空間，讓模型在隨機生成初期能快速找到資料的大致位置；小雜訊則負責在後期精修細節。
- b. 高品質生成：透過「退火」(Annealing)過程，即從大雜訊逐步降噪到小雜訊，能夠生成出既具備全局結構又擁有精細紋理的高品質圖像，這是單一 σ 模型做不到的。

文獻支持: **Denoising Diffusion Probabilistic Models** (Jonathan Ho, Ajay Jain, Pieter Abbeel, 2020, NeurIPS)(<https://arxiv.org/pdf/2006.11239>)

8. 如果在 SDE 中的 drift 及 diffusion 常數改成由模型學習而不是事先固定，會有更好的表現嗎？還是說反而會破壞掉現有 SDE 的理論架構？

是的，讓模型學習這些係數通常能帶來更好的表現（特別是在 Log-likelihood 方面），而且這並不會破壞 SDE 的理論架構，反而是將其延伸到了更廣義的框架(如薛丁格橋 Schrödinger Bridge)中。

文獻支持：**Variational Diffusion Models** (Diederik P. Kingma, Tim Salimans..., 2021, NeurIPS)(<https://arxiv.org/abs/2107.00630>), **Score-Based Generative Modeling through Stochastic Differential Equations** (Yang Song, Jascha Sohl-Dickstein..., 2021, ICLR)(<https://arxiv.org/abs/2011.13456>), **Diffusion Schrödinger Bridges with Applications to Score-Based Generative Modeling** (Valentin De Bortoli, James Thornton..., 2021, NeurIPS) (<https://arxiv.org/abs/2106.01357>)

9. (Week10) 在 Reverse SDE 中，模型會一步步去除噪聲，恢復出真實的資料樣本。但在現實世界中，像是天氣預測或金融市場中，資料中的噪聲往往並不是論文假設的「高斯噪聲」，而是未知或依據資料特性改變的「非高斯噪聲」。我想問如果正向過程的噪聲並非高斯分佈，甚至依賴資料本身，那反向 SDE 還能穩定且可靠的重建出原始訊號嗎？

如果噪聲是非高斯的，標準的反向 SDE 會失效。但是，透過使用 Lévy SDEs (針對重尾/跳躍噪聲) 或 Cold Diffusion / Schrödinger Bridges (針對任意退化)，我們依然可以建立穩定可靠的重建模型。

文獻支持：**Score-based Generative Modeling with Lévy Processes** (Hwin Kim, Jungwon Choi..., 2023, NeurIPS)(<https://openreview.net/forum?id=ErzyBARv6Ue>),

Cold Diffusion: Inverting Arbitrary Image Transforms Without Noise (Arpit Bansal, Eitan Borgnia..., 2022, CVPR)(<https://arxiv.org/abs/2208.09392>), **Diffusion Schrödinger Bridges with Applications to Score-Based Generative Modeling** (Valentin De Bortoli, James Thornton..., 2021, NeurIPS) (<https://arxiv.org/abs/2106.01357>)